SAFENET KZ

Техникалық құжаттама

Жүйе қалай жұмыс істейді: деректер, алгоритмдер, машиналық оқыту, сапа және қолдану

Әлеуметтік желілердегі контенттен ақылы ұтыстардың, онлайн-казинoның жасырын жарнамасының және қаржы пирамидаларының **белгілерін** анықтайтын, нәтижесін түсіндіретін және кейстерді аналитикке басымдық бойынша ұсынатын жүйе.

Ақылы ұтыстар | Онлайн-казино жарнамасы | Қаржы пирамидалары

Нұсқа: MVP + продакшнға дайындау (коммит `0bb2ffe`, тармақтар `main` / `safenet-mvp`)

Күні: 2026 жылғы 23 қазан

Технологиялар: Python · Django · django-ninja · scikit-learn · Tesseract OCR · NetworkX

Тілдер: қазақ, орыс, аралас тіл, транслит

Мазмұны

1. Жүйе туралы — мақсаты, үш трек, негізгі қағида
2. Жалпы жұмыс схемасы — өңдеу тізбегі, бір жазбаның жолы
3. Деректер — синтетикалық датасет, gold-жинақ, бөліністер
4. Мәтінді алдын ала өңдеу — тілді анықтау, бүркемелеуді ашу, нысандар
5. Белгілер сөздігі (ережелер) — 27 белгі, есептелетін белгілер, үйлесімдер
6. ML-классификатор — TF-IDF, логистикалық регрессия, калибрлеу
7. Гибрид скоринг және тәуекел деңгейлері — формула, шектер, мысалдар
8. Скриншоттар: OCR — Tesseract, суретті алдын ала өңдеу
9. Байланыстар графы — кластерлер, Louvain, желі бонусы
10. Нәтиже және түсіндірме — жауап құрылымы
11. Веб-қосымша: дашборд және API — беттер, рөлдер, API
12. Сапаны бағалау — метрикалар, абляция, қателер
13. Өнімділік және масштабтау
14. Қауіпсіздік, деректерді қорғау және этика
15. Орнату және іске қосу
16. Шектеулер және даму жоспары

Қосымша А. Жоба құрылымы
Қосымша Б. Терминдер сөздігі

> **Құжат туралы.** Бұл құжатта SafeNet KZ жүйесінің толық сипаттамасы берілген: ол қандай деректерде оқытылды, мәтін қандай алгоритмдермен өңделеді, қандай машиналық оқыту әдістері қолданылды, тәуекел ұпайы қалай есептеледі және жүйенің сапасы қалай өлшенді. Барлық сандар жобаның есептерінен (`reports/`) және конфигурация файлдарынан (`config/` , `models/`) алынған.

1 Жүйе туралы

1.1. Мақсаты

SafeNet KZ — уәкілетті орган аналитиктеріне арналған жүйе. Ол әлеуметтік желілердегі контентті талдап, үш түрлі заңсыз схеманың **белгілерін** табады. Сонымен қатар әр нәтиженің неліктен шыққанын түсіндіріп, күдікті жазбаларды тексеру кезегіне басымдық бойынша қояды.

Жүйе мына контент түрлерін талдайды:

- **посттар** мен **чат хабарламалары** (Telegram, WhatsApp, Instagram, TikTok, YouTube, VK);
- **профиль сипаттамалары** (bio);
- **эфир транскрипциялары**, яғни тікелей эфирдің мәтінге айналдырылған нұсқасы;
- **скриншоттар**: суреттегі мәтінді жүйе OCR арқылы оқиды.

Қолдау көрсетілетін тілдер: **орыс**, **қазақ**, **аралас тіл** (бір хабарламада екі тіл) және **транслит** (кирилл сөздердің латынша жазылуы). Бүркемеленген жазулар да танылады: «к@зино», «Л о т е р е я», гомоглифтер және эмодзи.

1.2. Үш трек

Трек	Схеманың мәні	Типтік белгілері
lottery **Ақылы ұтыстар**	Ұйымдастырушы «розыгрышқа» қатысу үшін ақша жинайды, жеңімпазды кездейсоқ таңдайды. Бұл лицензиясыз лотерея болып табылады: ұйымдастырушы сатылған «слоттардан» пайда табады.	ақылы қатысу («слот 2000 ₸»), рандомайзер, «продано 80 из 100», картаға аударым
casino **Онлайн-казино жарнамасы**	Блогерлер мен арналар заңсыз онлайн-казиноны жасырын жарнамалайды: ұтыстарымен мақтанады, промокод таратады, бұғаттауды айналып өтетін «айна» сайттарға сілтеме береді.	«мой занос x100», промокод, депозитке бонус, «рабочее зеркало», реферал сілтеме
pyramid **Қаржы пирамидалары**	Шынайы емес жоғары табыс уәде етіліп, салым жиналады. Табыс жаңа қатысушылардың ақшасынан төленеді, көпдеңгейлі рефералдық құрылым жиі кездеседі.	«вложи 10 000 — получи 30 000 через неделю», кепілдік, «без риска», деңгейлер мен кураторлар

1.3. Негізгі қағида: үкім емес, белгілер

> Жүйе ешкімге айып тағып, кінәлі деп таныстырмайды. Ол **«нені тексеру керек және неліктен?»** деген сұраққа жауап береді. Соңғы шешімді әрқашан маман қабылдайды. Әр нәтиже карточкасында және әр API жауабында мына ескерту тұрады:
>
> *«Ықтимал бұзушылықтың белгілері анықталды. ҚР заңнамасын ескере отырып, маманның тексеруі қажет.»*

Сондықтан жүйе тек белгілерді табумен шектелмейді. Әр нәтижеде мыналар болады:

- **тәуекел ұпайы** (0–100) және **деңгейі**: Төмен, Орташа немесе Жоғары;

- схеманың **ең ықтимал түрі** (трек);
- іске қосылған **белгілер**, әрқайсысына мәтіннен алынған **дәлел-фрагмент**;
- **ұпайдың құрамы**: ұпайға әр бөліктің қанша қосқаны;
- қазақ және орыс тіліндегі **түсіндірме** мен **ескерту**.

1.4. Тәсіл: гибрид жүйе

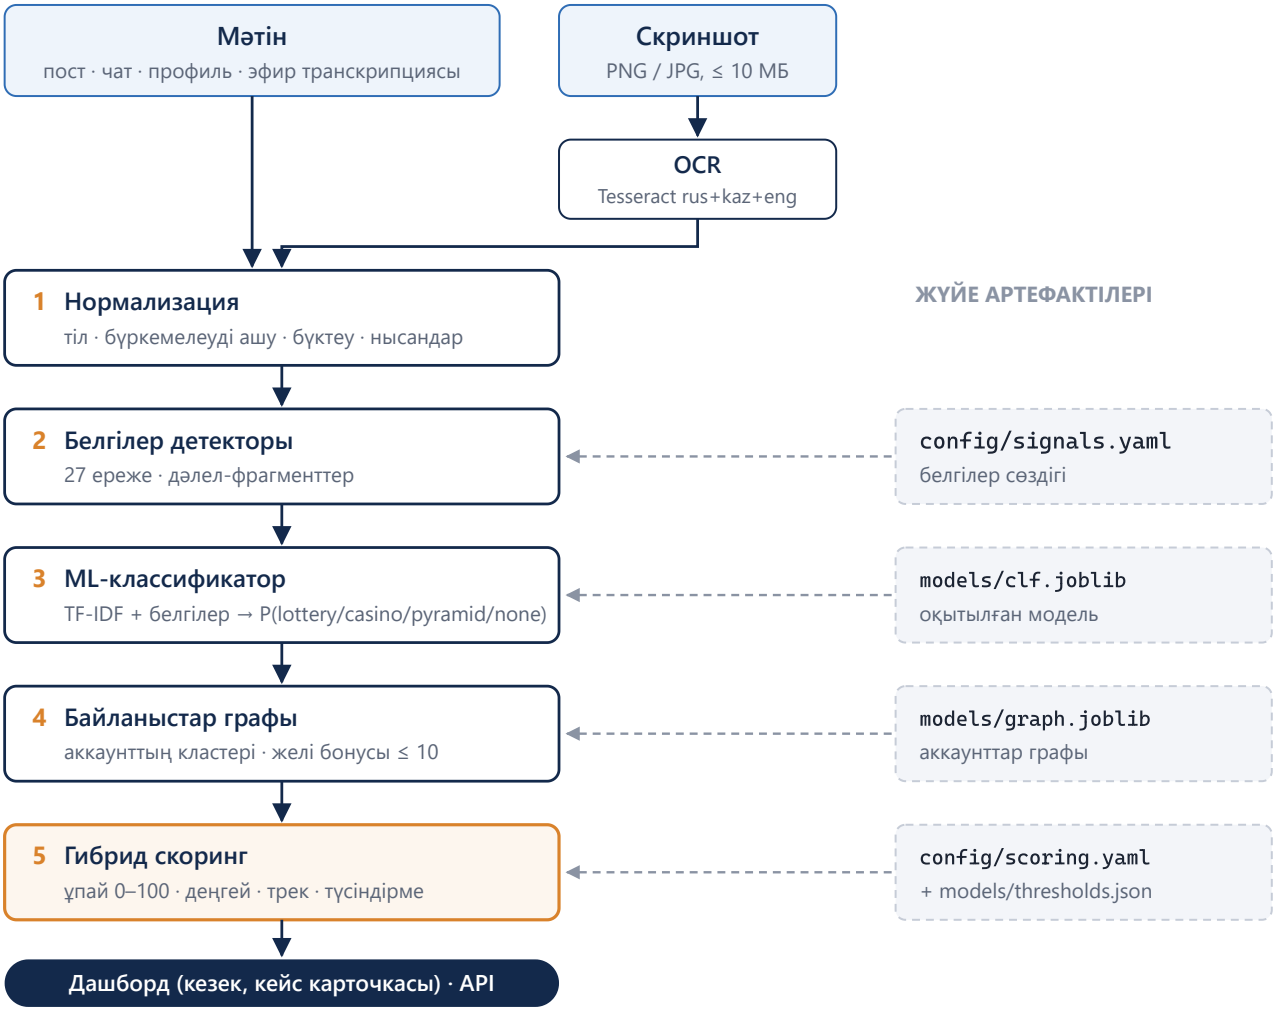
SafeNet KZ төрт тәсілді біріктіреді. Әрқайсысы басқасының әлсіз жағын толықтырады:

Құрамдас бөлік	Не істейді	Неге керек
Ережелер (белгілер сөздігі)	27 белгіні кілт сөздер, regex үлгілері және есептеулер арқылы табады	Түсіндірілетін, дәлел береді, деректі көп талап етпейді
Машиналық оқыту (ML)	Мәтінді 4 класқа жіктейді: lottery / casino / pyramid / none	Сөздікте жоқ тұжырымдарды да жалпылап таниды
OCR	Скриншоттағы мәтінді оқиды	Схемалар жиі сурет түрінде таратылады
Байланыстар графы	Ортақ карта, телефон немесе промокод арқылы байланысқан аккаунттарды табады	Жеке постты емес, ұйымдасқан желіні көрсетеді

2 Жалпы жұмыс схемасы

2.1. Өңдеу тізбегі

Әр жазба бір функциядан өтеді: `safenet.pipeline.analyze()`. Дашборд та, API да осы бір функцияны шақырады, сондықтан нәтиже екеуінде де бірдей.



1-сурет. Бір жазбаның өңдеу тізбегі. Сол жақта — өңдеу сатылары, оң жақта — әр сатының файлдары.

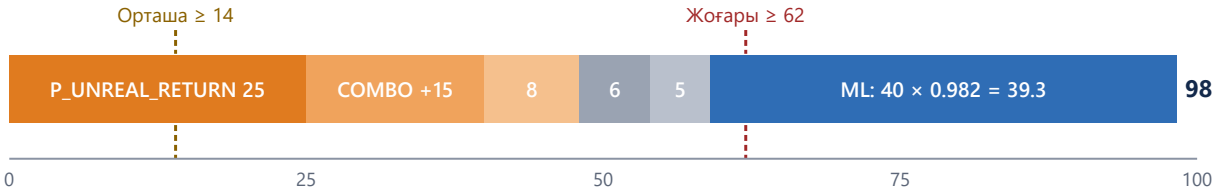
#	Саты	Не істейді	Модуль
0	OCR (скриншот болса)	Суретті тазалап, мәтінін Tesseract арқылы оқиды; сенімділігі төмен сөздерді алып тастайды	`multimodal/ocr.py`
1	Нормализация	Тілді анықтайды, бүркемелеуді ашады, қазақ әріптерін «бүктейді», нысандарды бөліп алады (сома, %, карта, телефон, сілтеме, промокод)	`preprocess/`
2	Белгілер детекторы	Сөздіктегі 27 ережені орындайды, әр белгіге мәтіндегі дәл орнын (дәлел) береді	`signals/`
3	ML-классификатор	Мәтіннің 4 класқа жату ықтималдығын береді	`ml/`
4	Байланыстар графы	Жазба авторы күдікті кластерге кірсе, желі бонусын береді	`graph/`
5	Скоринг	Барлығын бір формулаға біріктіреді: ұпай, деңгей, трек, түсіндірме	`scoring/`

2.2. Мысал: бір жазбаның жолы

Мына пост жүйеден өткізілді (нәтиже нақты, жүйенің өзінен алынған):

```
Вложи 10 000 — через неделю получишь 30 000! Гарантированно, без риска. Пиши в лс, осталось 5 мест.
```

1. **Нормализация.** Тіл — `ru`. Нысандар: екі сома (10 000 және 30 000), мерзім — «неделя» (7 күн).
2. **Белгілер.** Төрт белгі іске қосылды:
   - P_UNREAL_RETURN ★ «Вложи 10 000 — через неделю получишь 30 000». Жүйе табысты өзі есептеді: 7 күнде +200%, яғни айына **857%**. Бұл 30% шегінен әлдеқайда жоғары;
   - P_GUARANTEE «Гарантированно», «без риска»;
   - C_URGENCY «осталось 5 мест»;
   - C_DM_REDIRECT «Пиши в лс».
3. **Үйлесім.** Шынайы емес табыс пен асықтыру бірге кездесті, сондықтан `COMBO_PYRAMID` іске қосылды (+15).
4. **ML.** Модель: *pyramid* ықтималдығы 0.982 → үлесі 40 × 0.982 = **39.3**.
5. **Граф.** Аккаунт көрсетілмеген, сондықтан желі бонусы 0.
6. **Скоринг.** Ережелер: 25 + 8 + 6 + 5 + 15 = 59. Барлығы: 59 + 39.3 = **98** → Жоғары, трек — қаржы пирамидасы.



Қызғылт сары — пирамида белгілері мен үйлесім, сұр — ортақ белгілер, көк — ML үлесі.

2-сурет. Мысалдағы ұпайдың құрамы. Кейс карточкасында дәл осындай диаграмма көрсетіледі.

3 Деректер

Нақты, белгіленген деректер жоқ болғандықтан және жеке деректерді қорғау талабы болғандықтан, жүйе **синтетикалық** деректерде оқытылды. Деректер генераторы (`safenet.generator` , `make data`) шаблондар мен фраза жиынтықтарынан хабарламалар құрастырады. Сапаны тәуелсіз тексеру үшін бөлек, қолмен жазылған **gold-жинақ** бар.

3.1. Синтетикалық датасет

Көрсеткіш	Мәні
Барлық жазба	**2400**
Шаблондар	430
Скриншоттар (PNG)	130
Қиын негативтер	540 (none-дың 56.2%)
Бүркемеленген схемалар	32.8%
Бүркемеленген негативтер	10.3%
Толық / дерлік көшірмелер	0 / 0.00%
Gold-жинақ (қолмен)	**122**

Класс	Саны	%
none (схема емес)	960	40.0
lottery	480	20.0
casino	480	20.0
pyramid	480	20.0

Тіл	Саны	%
орыс (ru)	1080	45.0
қазақ (kk)	695	29.0
аралас (mixed)	335	14.0
транслит	290	12.1

Дереккөз түрі	Саны	%	Сипаттамасы
post	1050	43.8	арнадағы немесе парақтағы пост
chat_message	795	33.1	чат немесе топ хабарламасы
account_bio	215	9.0	профиль сипаттамасы
stream_transcript	210	8.8	эфир транскрипциясы
screenshot	130	5.4	скриншот (мәтін суретте)

3.2. Қиын негативтер

Қиын негатив — схемаға өте ұқсайтын, бірақ схема емес мәтін. Жалған іске қосылулардың басты көзі осындай мәтіндер, сондықтан олар деректе әдейі көп (none класының жартысынан астамы). Мысалдар:

- тегін розыгрыш («подпишись и отметь друга»);
- банк депозиті («14% годовых»);
- киберспорт турнирі (жеңімпазды кездейсоқтық емес, ойын нәтижесі анықтайды);
- мемлекеттік лицензиялы лотерея;
- дүкен акциясы;
- схемалар туралы ескерту немесе жаңалық («АФМ предупреждает…»).

3.3. Бөліністер және ағып кетудің алдын алу

Деректер үш бөлікке бөлінген: **train** (оқыту) — 1441, **val** (баптау) — 477, **test** (тексеру) — 482. Бөлу кездейсоқ жазба бойынша емес, **шаблон мен фраза тұқымы** бойынша жасалады:

- әр фраза нұсқасы бір «тұқымға» жатады (нұсқа нөмірі % 5);

- 0–2 тұқымдар → train, 3 → val, 4 → test;
- бөліністер арасында ортақ шаблон **жоқ** (train∩val = train∩test = val∩test = 0).

Сондықтан test жинағындағы тұжырымдар оқыту кезінде мүлде кездеспейді. Модель жаттап алған фразаларды емес, жалпылау қабілетін көрсетеді.

3.4. Gold-жинақ

Gold — қолмен жазылған 122 хабарлама (`data/gold/gold_source.yaml`). Олар генератордан тәуелсіз, «нақты өмірге» жақын жазылған. Gold тек **соңғы бағалауға** қолданылады: белгілер сөздігі, модель және шектер ол бойынша бапталмаған. Әр gold жазбасында эталон класс, эталон тәуекел деңгейі және эталон белгілер (`gold_signals`) көрсетілген.

3.5. Ендірілген желілер

Граф алгоритмін тексеру үшін деректерге **10 жасырын желі** салынған. Әр желінің аккаунттары ортақ карта, телефон, промокод, домен немесе қысқа сілтеме қолданады. Сонымен қатар ортақ сайты бар **2 заңды дүкен** «тұзақ» ретінде қосылған: жүйе оларға желі бонусын бермеуі керек.

> **Деректердің қауіпсіздігі.** Барлық деректер ойдан шығарылған: карта нөмірлері Лун тексерісінен өтпейді, домендер тек `.test` / `.example` аймақтарында, адамдар тек никнеймдермен аталады, казино мен жобалардың атаулары ойдан шығарылған.

4 Мәтінді алдын ала өңдеу

Әлеуметтік желі мәтіні «лас»: екі тіл араласады, сөздер әдейі бұрмаланады, сомалар әртүрлі жазылады. Нормализация (`safenet.preprocess.normalize`) мәтінді ережелер мен модель түсінетін бірыңғай түрге келтіреді. Бір жазбаға орташа **0.46 мс** жұмсалады.

4.1. Тілді анықтау

Алгоритм екі қадамнан тұрады:

1. **Транслит.** Мәтіндегі латын әріптерінің үлесі есептеледі. Ол жоғары болса және сөздер кирилл сөздердің латынша жазылуына ұқсаса, тіл — `translit`.
2. **Сөздер бойынша дауыс беру.** Әр сөз бір тілге «дауыс береді»:
   - **қазақ тіліне**, егер сөзде қазақ әрпі (ә, ғ, қ, ң, ө, ұ, ү, h, і) болса, сөз жиі қолданылатын қазақ сөздерінің тізімінде болса немесе типтік қазақ жұрнағымен аяқталса;
   - **орыс тіліне**, егер сөз жиі қолданылатын орыс сөзі болса немесе тек орыс тіліне тән жалғаумен аяқталса;
   - ортақ кірме сөздер (казино, депозит, бонус…) ешкімге дауыс бермейді.

   Дауыстар арақатынасы бойынша нәтиже: `ru` , `kk` немесе `mixed` .

Тіл	Дәлдік
орыс	99.7%
қазақ	98.4%
транслит	100.0%
аралас	72.8%
Жалпы	**95.6%**

Аралас тілді анықтау ең қиын: қай тілдің басым екені шартты. Бірақ белгілер мен модель «бүктелген» мәтінде жұмыс істейтіндіктен (4.3), бұл қате анықтау сапасына аз әсер етеді.

4.2. Бүркемелеуді ашу

Тәсіл	Мысал	Не істеледі
Гомоглифтер (латын ↔ кирилл)	«казино» (латын a, o)	Кирилл сөз ішіндегі латын әріптері кирилл әріптерге ауыстырылады
Leet-таңбалар	«к@зин0», «$лот»	@→а, 0→о, 3→з, $→с, 6→б, 4→ч
Әріп арасындағы бос орын	«Л о т е р е я»	Бөлек әріптер бір сөзге біріктіріледі
Көрінбейтін таңбалар	нөлдік ені бар бос орындар	Алынып тасталады
Сызықшалар мен тырнақшалар	— – – « » “ ”	Бір түрге келтіріледі
Транслит	«vlozhi 10k»	Кириллицаға аударылады

4.3. Қазақ әріптерін «бүктеу»

Бір ереже екі тілде де жұмыс істеуі үшін мәтіннің бүктелген көшірмесі жасалады (`folded` өрісі): ә→а, ғ→г, қ→к, ң→н, ө→о, ұ→у, ү→у, h→х, і→и, сондай-ақ ё→е, э→е, ъ→ь. Маңызды қасиеті: **ұзындық сақталады**. Сондықтан бүктелген мәтінде табылған дәлелдің орны түпнұсқа мәтінде дәл бөлектеледі.

4.4. Нысандарды бөліп алу

Мәтіннен құрылымды нысандар бөлініп алынады. Олар белгілерде (мысалы, табысты есептеу) және графта (ортақ реквизиттер) қолданылады.

Нысан	Қандай жазулар танылады	Recall
Сома	«5к», «10 000 тг», «5 мың теңге», «₸»	—
Пайыз, мерзім, көбейткіш	«30% в месяц», «за неделю», «x2»	—
Карта	толық және маскаланған нөмірлер («4400 43** **** 1234»)	100.0%
Телефон	+7 / 8 форматтары	100.0%
Домен, сілтеме	URL, домендер, қысқартқыштар (bit.ly…), `?ref=`, `utm_`	100.0%
Промокод	«промокод WIN50»	98.6%
Kaspi	Kaspi аударымы туралы айтылуы	—

Recall — генератор мәтінге салған нысандардың қаншасы табылғаны.

5 Белгілер сөздігі (ережелер)

5.1. Белгі қалай сипатталады

Әр белгі `config/signals.yaml` файлында сипатталған. Сөздікті өзгерту үшін кодты өзгерту керек емес. Әр белгінің құрамы:

- **трек** (lottery / casino / pyramid / ортақ / төмендететін) және **салмақ** — ұпайға қосатын үлесі;
- **негізгі (★)** белгісі: «Жоғары» деңгей үшін кемінде бір негізгі белгі міндетті;
- орыс және қазақ тіліндегі **кілт сөздер** мен **regex үлгілері**;
- **контекст-ерекшеліктер**: белгіні өшіретін сөздер (мысалы, «бесплатно», «турнир», «годовых»);
- **нысан талаптары**: мысалы, сома кілт сөзден 32 таңбадан алыс тұрмауы керек.

Детектор (`safenet.signals.detect`) үлгілерді бүктелген мәтінде орындайды. Әр іске қосылған белгі **дәлел-фрагменттерін** қайтарады: мәтіндегі бастапқы және соңғы позиция, фрагмент мәтіні және дереккөзі (`text` , `ocr` немесе `transcript`).

5.2. Есептелетін белгілер

Екі белгі кілт сөзбен емес, **есептеу** арқылы іске қосылады:

$$\text{айлық табыс (\%)} = \text{табыс (\%)} \times 30 \,/\, \text{мерзім (күн)}, \quad \text{табыс (\%)} = (\text{алынатын сома} - \text{салым}) \,/\, \text{салым} \times 100$$

- **P_UNREAL_RETURN** ★ — айлық табыс **≥ 30%** болса іске қосылады. Сомалар мен мерзім мәтіннен алынады. Мысалы: 10 000 → 30 000 бір аптада = +200% / 7 күн = айына 857%.
- **N_BANK_RATE** (төмендететін) — жылдық мөлшерлеме **≤ 20%** болса, бұл қалыпты банктік ставка деп танылады және ұпай азаяды.

5.3. Барлық белгілер

Барлығы **27** белгі: 4 негізгі (★), 17 қосымша және 6 төмендететін.

id	Трек	Атауы	Салмақ	Мысал тұжырымдар
`C_PAY_TRANSFER`	ортақ	Картаға / Kaspi-ге аударым	8	«перевод на Kaspi», «реквизиты в личке»
`C_PERSONAL_CARD`	ортақ	Карта нөмірі / жеке карта	10	карта нөмірі, «на мою карту»
`C_URGENCY`	ортақ	Асықтыру	6	«осталось N мест», «только сегодня»
`C_REFERRAL`	ортақ	Дос шақыру үшін бонус	6	«приведи друга», бонус за приглашённого
`C_SHORTLINK`	ортақ	Жасырын сілтеме / қысқартқыш	6	bit.ly, «ссылка в био / в шапке»
`C_DM_REDIRECT`	ортақ	Жеке хатқа шақыру	5	«пиши в лс», «жеке жаз»
`L_PAID_ENTRY` ★	ұтыс	Ұтысқа ақылы қатысу	25	взнос, слот, билет за деньги
`L_RANDOM_DRAW` ★	ұтыс	Жеңімпазды кездейсоқ таңдау	15	рандомайзер, колесо, random.org
`L_ORGANIZER_PROFIT`	ұтыс	Ұйымдастырушы табысы	10	«продано 80 из 100», N номеров × цена
`L_SERIES`	ұтыс	Сериялы ұтыстар	6	«розыгрыш №14», «каждую пятницу»
`K_GAMBLING_TERMS` ★	казино	Құмар ойын терминдері	25	казино, слоты, ставки, фриспины

id	Трек	Атауы	Салмақ	Мысал тұжырымдар
`K_WIN_BRAG`	казино	Ұтысты мақтану	10	«мой занос», «вывод пришёл», «x100»
`K_PROMO_BONUS`	казино	Промокод / депозитке бонус	10	промокод, бонус к депозиту
`K_REF_TRACKING`	казино	Рефералдық / трекинг сілтеме	8	`?ref=`, `utm_`, «моя реф-ссылка»
`K_MIRROR`	казино	Айна / бұғаттауды айналып өту	10	«рабочее зеркало», «без VPN»
`K_STREAM_CTA`	казино	Тіркелуге шақыру	8	«регайтесь по моей ссылке»
`P_UNREAL_RETURN` ★	пирамида	Шынайы емес табыс уәдесі	25	есептелетін: айына ≥ 30%, «x2 за неделю»
`P_GUARANTEE`	пирамида	Табысқа кепілдік / тәуекелсіз	8	«гарантированно», «без риска», «кепілді табыс»
`P_REFERRAL_TIERS`	пирамида	Көпдеңгейлі рефералдық модель	12	линии, уровни, % с вкладов приглашённых
`P_PAYOUT_PROOF`	пирамида	«Төлем скриндері», жылыту	10	«скрины выплат», «уже вывела»
`P_ORG_STRUCTURE`	пирамида	Куратор / тәлімгер / «команда»	8	кураторы, закрытый чат
`N_FREE_ENTRY`	төменд.	Тегін қатысу	−25	«подписка + лайк», «бесплатно»
`N_WARNING_CONTEXT`	төменд.	Ескерту / жаңалық / ағарту	−30	«осторожно», «АФМ предупреждает»
`N_COMMERCE`	төменд.	Қалыпты сауда / дүкен акциясы	−20	тауар + баға + жеткізу
`N_BANK_RATE`	төменд.	Банктік мөлшерлеме	−25	есептелетін: жылдық ≤ 20%
`N_SKILL_EVENT`	төменд.	Шеберлік жарысы (турнир)	−15	турнир, матч, нәтиже бойынша жеңіс
`N_OFFICIAL_LOTTERY`	төменд.	Мемлекеттік лотерея	−30	ресми оператор, лицензия

5.4. Белгілердің үйлесімі

Схеманың «қаңқасын» құрайтын белгілер бірге кездессе, қосымша бонус беріледі. Жеке белгіден гөрі олардың бірге кездесуі схеманы әлдеқайда сенімді көрсетеді.

id	Трек	Шарт	Бонус
`COMBO_LOTTERY_DRAW`	ұтыс	L_PAID_ENTRY + L_RANDOM_DRAW	+15
`COMBO_LOTTERY_PROFIT`	ұтыс	L_PAID_ENTRY + L_RANDOM_DRAW + L_ORGANIZER_PROFIT	+10
`COMBO_PYRAMID`	пирамида	P_UNREAL_RETURN + (C_URGENCY немесе P_REFERRAL_TIERS)	+15
`COMBO_CASINO`	казино	K_GAMBLING_TERMS + (K_PROMO_BONUS, K_REF_TRACKING немесе K_STREAM_CTA)	+15

6 ML-классификатор

6.1. Міндет

Модель әр мәтіннің 4 класқа жату ықтималдығын береді: **lottery**, **casino**, **pyramid** және **none** (схема белгілері жоқ). Ережелер тек сөздікте бар тұжырымдарды табады, ал модель жаңа, бірақ ұқсас тұжырымдарды да жалпылап тани алады.

6.2. Фичалар (белгілер векторы)

Мәтін үш бөліктен тұратын сандық векторға айналады:

Бөлік	Сипаттамасы	Неге керек
Символдық n-граммдар TF-IDF, 2–5 таңба, `char_wb`, ≤ 60 000	Сөз ішіндегі 2–5 әріптік тізбектер («каз», «азин», «зино»). Бүктелген, нормаланған мәтінде есептеледі.	Бүркемелеуге, қателерге және қазақ тілінің жалғауларына төзімді
Сөздік n-граммдар TF-IDF, 1–2 сөз, ≤ 30 000	Жеке сөздер мен сөз жұптары («условия участия», «скину лично»)	Тұрақты тіркестерді ұстайды
Сандық белгілер	Ережелер детекторының нәтижесі: әр белгінің жалаушасы (`sig:L_PAID_ENTRY`…), есептелген айлық табыс, сомалардың саны мен ең үлкен сомасы, карта/телефон бар-жоғы	Ережелер білімін модельге береді

TF-IDF терминнің құжаттағы маңыздылығын бағалайды: термин құжатта жиі кездессе (TF), бірақ корпуста сирек болса (IDF), салмағы жоғары болады. Әр вектор L2 бойынша нормаланады.

$$\text{tf-idf}(t, d) = \text{tf}(t, d) \times \text{idf}(t), \quad \text{idf}(t) = \ln\left((1 + N) \,/\, (1 + \text{df}(t)) \right) + 1$$

N — құжаттар саны, df(t) — t термині кездесетін құжаттар саны.

6.3. Модель: логистикалық регрессия

Классификатор — **көпкласты (softmax) логистикалық регрессия**. Ол әр класс k үшін салмақтар векторын w_k үйренеді және ықтималдықты былай есептейді:

$$P(k \mid x) = \exp(w_k \cdot x + b_k) \,/\, \Sigma_j \exp(w_j \cdot x + b_j)$$

- **Оңтайландыру:** lbfgs алгоритмі, L2-регуляризация; күші **C = 1.0**. C мәні val жинағында 0.5–32 аралығынан таңдалды.
- **Кластар теңгерімі:** `class_weight="balanced"`. Әр кластың қатесі оның жиілігіне кері пропорционал салмақ алады.
- **Калибрлеу:** сигмоидалық калибрлеу (Platt scaling, `CalibratedClassifierCV`). Калибрлеу бөліністері **шаблон бойынша** жасалады (GroupKFold, 3 бөлік). Сондықтан модельдің «90%» деген ықтималдығы шынымен шамамен 90%-ды білдіреді, бұл оны ережелер ұпайымен біріктіруге мүмкіндік береді.

6.4. Неге логистикалық регрессия?

- **Деректер аз:** 1441 оқыту жазбасы. Терең нейрожелілер мұндай көлемде оңай қайта оқытылып (overfitting), жалпылау қабілетін жоғалтады.

- **Түсіндірілетіндік:** әр фичаның салмағын көруге болады (6.6-бөлім).
- **Жылдамдық:** бір жазбаға (нормализация + белгілер + модель) шамамен 10 мс, тек CPU, GPU қажет емес.
- **Салыстыру мүмкіндігі:** жобада көптілді сөйлем эмбеддингтері (sentence-transformers) негізіндегі балама модель бар (`--embeddings`), бірақ ол PyTorch-ты талап етеді, сондықтан әдепкі бойынша қосылмаған.

Резервтік іске асыру: scikit-learn-нің компиляцияланған модульдері жүктелмейтін машиналарда дәл сол алгоритмнің numpy/scipy нұсқасы (`safenet/ml/linear.py`) автоматты түрде қолданылады.

6.5. Модель сапасы (val)

Класс	Precision	Recall	F1	n
lottery	1.000	0.823	0.903	96
casino	1.000	0.840	0.913	94
pyramid	1.000	0.866	0.928	97
none	0.809	1.000	0.894	190

Көрсеткіш	Мәні
macro-F1	**0.910**
accuracy	0.906
қиын негативтерде «схема» болжамы	0.0%
бір жазбаның инференсі	9.8 мс
толық оқыту уақыты	11.1 с

Модельдің өзі сақ: схема деп айтса, әрқашан дұрыс (precision 1.000), бірақ кейбір схемаларды өткізіп алады. Бұл олқылықты ережелер толтырады, сондықтан гибрид нәтижесі әлдеқайда жоғары (12-бөлім).

6.6. Модель нені маңызды деп санайды

Логистикалық регрессия коэффициенттері бойынша әр кластың ықтималдығын ең көп арттыратын фичалар:

Класс	Ең маңызды фичалар (салмақ)
lottery	L_PAID_ENTRY (2.25), L_RANDOM_DRAW (1.76), C_DM_REDIRECT (1.41), L_SERIES (0.65), C_PAY_TRANSFER (0.61), «участия»
casino	K_MIRROR (2.02), K_WIN_BRAG (1.88), C_SHORTLINK (1.38), K_GAMBLING_TERMS (1.33), ең үлкен сома (1.14), K_PROMO_BONUS (1.03)
pyramid	P_ORG_STRUCTURE (2.51), P_UNREAL_RETURN (1.77), айлық табыс (1.56), P_PAYOUT_PROOF (0.97), P_GUARANTEE (0.73)
none	N_COMMERCE (1.30), N_WARNING_CONTEXT (1.26), N_SKILL_EVENT (0.66), N_FREE_ENTRY (0.60), N_BANK_RATE (0.41)

Модель ережелер белгілерін және солармен байланысты сөздерді қолданады. Бұл модельдің «логикасы» адам түсінетін логикаға сәйкес келетінін көрсетеді.

7 Гибрид скоринг және тәуекел деңгейлері

7.1. Формула

```
rule_score  = min( Σ оң белгілердің салмағы + Σ үйлесім бонустары , 60 )
ml_score    = 40 × P(ең ықтимал схема класы)          − none класынан басқа
negative    = Σ төмендететін белгілердің салмағы
network     = min( желі бонусы , 10 )

risk_score  = clip( rule_score + ml_score − negative + network , 0 , 100 )
```

Содан кейін екі қорғаныс шектегіші қолданылады:

- **Негізгі белгі жоқ болса**, ұпай **45**-тен аспайды. «Жоғары» шегі 62 болғандықтан, негізгі белгісіз «Жоғары» деңгей мүмкін емес.
- **Дәлелі бар оң белгі мүлде жоқ болса**, ұпай «Орташа» шегінен төмен қалады. Яғни ML-дің жалғыз өзі жазбаны тексеру кезегіне жібере алмайды.

Параметр	Мәні	Мағынасы
`rule_cap`	60	ережелер бөлігінің жоғарғы шегі
`ml_weight`	40	ML ықтималдығының салмағы
`network_max`	10	желі бонусының жоғарғы шегі
`no_core_cap`	45	негізгі белгі болмаса ұпайдың жоғарғы шегі
`require_evidence_for_medium`	иә	дәлелсіз жазба «Орташа» деңгейге жетпейді

Ұпайдың әр құрамдас бөлігі нәтижеде бөлек көрсетіледі. Олардың қосындысы дәл ұпайға тең, сондықтан аналитик ұпайдың қайдан шыққанын толық көре алады.

7.2. Деңгейлер

Деңгей	Ұпай	Мағынасы
Төмен	0 – 13	Елеулі белгілер жоқ
Орташа	14 – 61	Тексеруді қажет етеді
Жоғары	62 – 100	Басым тәртіппен тексеру қажет

7.3. Шектер қалай таңдалды

Шектерді `safenet.scoring.tune` модулі **тек val жинағы** бойынша автоматты түрде таңдайды (test пен gold қолданылмайды):

- **Орташа = 14.** Шарттар: precision ≥ 0.85 және қиын негативтердегі FPR ≤ 10%. Осы шарттар орындалатын шектердің ішінен recall-ы ең жоғарысы таңдалады. Іздеу аралығы — 10–64.
- **Жоғары = 62.** Шарттар: 45-тен (`no_core_cap`) жоғары, «Жоғары» деңгейдің precision-ы ≥ 0.95, эталон деңгейлермен келісім барынша жоғары. Іздеу аралығы — 46–95.

Шектер `models/thresholds.json` файлында сақталады. val нәтижесі: precision 1.000, recall 1.000, қиын негативтердегі FPR 0.0%.

7.4. Трек қалай таңдалады

Әр трек үшін жеке ұпай есептеледі: сол тректің белгілері мен үйлесімдері + 40 × модельдің сол трекке берген ықтималдығы. Ең жоғары ұпай алған трек — **ең ықтимал схема түрі**. Оң белгі жоқ болса және модель «none» десе, трек — «белгілер жоқ».

7.5. Мысалдар

Төмендегі нәтижелердің бәрі жүйенің өзінен алынған:

Мәтін	Не табылды	Ұпай	Деңгей
«Вложи 10 000 — через неделю получишь 30 000! Гарантированно, без риска. Пиши в лс, осталось 5 мест.»	P_UNREAL_RETURN 25, P_GUARANTEE 8, C_URGENCY 6, C_DM_REDIRECT 5, COMBO_PYRAMID 15; ML pyramid 0.98 → +39.3	**98**	Жоғары пирамида
«Ұтыс! Қатысу 1000 теңге, Kaspi-ге аударыңыз. Жеңімпазды рандомайзер таңдайды.» (қазақша)	L_PAID_ENTRY 25, L_RANDOM_DRAW 15, C_PAY_TRANSFER 8, COMBO_LOTTERY_DRAW 15 → 63, шекпен 60; ML lottery 0.91 → +36.3	**96**	Жоғары ұтыс
«Мой занос x100 в к@зино! Промокод WIN50 — бонус к депозиту, рабочее зеркало в шапке профиля.» (бүркемеленген)	K_GAMBLING_TERMS 25, K_WIN_BRAG 10, K_PROMO_BONUS 10, K_MIRROR 10, C_SHORTLINK 6, COMBO_CASINO 15 → шекпен 60; ML casino 0.999 → +40	**100**	Жоғары казино
«Осторожно! АФМ предупреждает: обещания „вложи 10 000 — через неделю получишь 30 000“ — признак пирамиды. Не ведитесь.»	P_UNREAL_RETURN 25; ML pyramid 0.30 → +11.9; **N_WARNING_CONTEXT −30**	**7**	Төмен
«Депозит в банке: 14% годовых, система гарантирования депозитов.»	**N_BANK_RATE −25**; ML pyramid 0.01 → +0.4	**0**	Төмен

Соңғы екі мысал маңызды. Ескерту мәтінінде пирамиданың нақты тұжырымы бар, бірақ төмендететін белгі оны «ескерту» деп таниды. Банк депозиті туралы мәтінде пайыз бар, бірақ жылдық 14% қалыпты ставка болып саналады.

8 Скриншоттар: OCR

Схемалар жиі сурет түрінде таратылады: төлем түбіртектері, «выплаттардың» скриншоттары, баннерлер. Жүйе суреттегі мәтінді оптикалық таңбаларды тану (OCR) арқылы оқып, оны кәдімгі мәтін сияқты талдайды.

8.1. OCR қозғалтқышы

- **Tesseract 5**, LSTM режимі (`--oem 1`), бет сегментациясы — біркелкі мәтін блогы (`--psm 6`).
- Тілдер: **rus + kaz + eng** (tessdata_fast модельдері, `models/tessdata`).
- Tesseract болмаса, EasyOCR қолданылады. Ол да болмаса, жүйе мәтінмен жұмысын жалғастырады, ал нәтижеге ескерту қосылады.

8.2. Суретті алдын ала өңдеу

OCR сапасы суреттің тазалығына тікелей байланысты. Сондықтан сурет мына тізбектен өтеді:

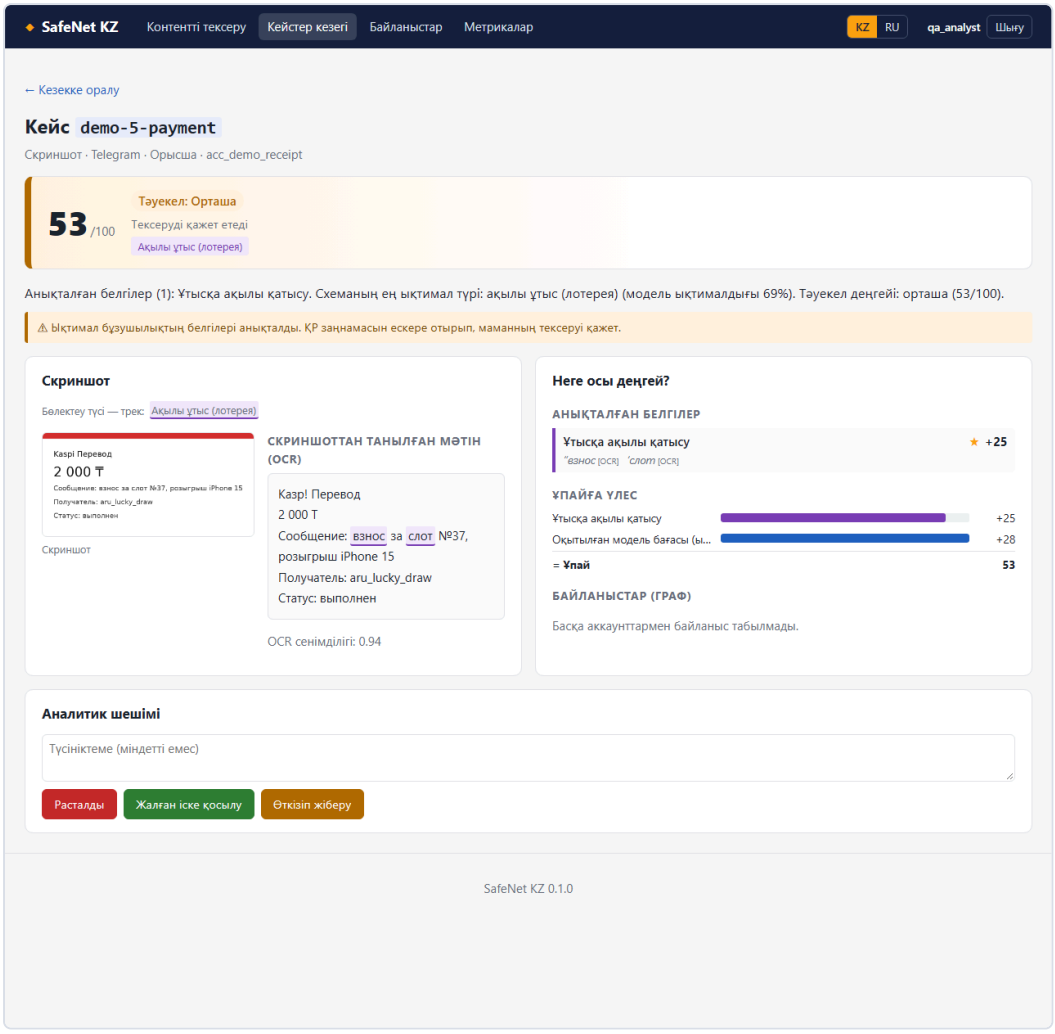
1. EXIF бойынша бұру, **сұр реңкке** айналдыру;
2. ені 700 пикселден аз болса, **2 есе үлкейту** (Lanczos);
3. фон қараңғы болса (dark mode), **түстерді инверсиялау**;
4. шуды азайту үшін **медианалық сүзгі** (3×3);
5. **Otsu бинаризациясы**: қара мәтін мен ақ фонды бөлетін шекті автоматты түрде табу;
6. тұтас түсті жолақтарды (тақырып, бөлгіштер) алып тастау;
7. **қисаюды түзету** (±5°): жолдар профилі ең өткір болатын бұрыш ізделеді;
8. нәтиже — ақ фонда таза қара мәтін.

8.3. Танудан кейінгі өңдеу

- Сенімділігі **30-дан төмен** сөздер алынып тасталады.
- Белгілі сөздердегі жиі қателер түзетіледі (редакциялық қашықтық ≤ 1). Мысалы, «Каврі» → «Kaspi».
- OCR мәтіні сол белгілер детекторымен талданады. Дәлелдің дереккөзі `ocr` деп белгіленеді.
- Мәтін мен скриншот бірге келсе, екеуінің белгілері біріктіріледі.

8.4. Нәтижелер (130 синтетикалық скриншот)

Көрсеткіш	Мәні	Талап
Негізгі токендердің қалпына келуі (сомалар, «каспи», «промокод», «выплата»)	**0.915**	≥ 0.80
Орташа сенімділік	0.935	—
Схема скриншоттары: Орташа немесе Жоғары деңгей	**88.9%**	≥ 75%
Қиын негатив скриншоттары: Төмен деңгей	**100.0%**	≥ 85%
Бір суретті өңдеу уақыты	0.37–0.43 с	—



3-сурет. Скриншоттан құрылған кейс: сол жақта сурет және одан танылған мәтін.

9 Байланыстар графы

Жеке пост әлсіз белгі беруі мүмкін, бірақ бірнеше аккаунт **бір картаны, бір телефонды немесе бір промокодты** қолданса, бұл ұйымдасқан желіні білдіреді. Граф модулі (`safenet.graph`, NetworkX кітапханасы) осындай желілерді табады.

9.1. Граф құрылымы

- **Түйіндер:** аккаунттар, топтар/арналар және нысандар — карта, телефон, домен, промокод, сілтеме.
- **Қабырғалар:** «аккаунт → нысан» (жазбада айтылды) және «аккаунт → топ» (сол жерде жариялады).
- **Жеке деректер:** карта мен телефон түйіндері тек **SHA-256 хэш** түрінде сақталады, экранда тек маска көрсетіледі (`+7 701 *** ** 78`). Цифрлары 6-дан аз белгілі маскалар байланыс ретінде қолданылмайды.

9.2. Кластерлеу алгоритмі

1. **Шулы түйіндерді алып тастау.** 12-ден көп аккаунтқа ортақ нысандар мен топтар (үлкен қоғамдық чаттар, танымал сайттар) алынады, әйтпесе бүкіл граф бір кластерге бірігіп кетер еді.
2. **Байланысқан компоненттер.** Қалған граф байланысқан компоненттерге бөлінеді. Кемінде 2 аккаунты бар компонент — кластер.
3. **Louvain алгоритмі.** 15-тен көп аккаунты бар үлкен компонент Louvain әдісімен қауымдастықтарға бөлінеді. Бұл әдіс граф модульдігін (Q) барынша арттырады, яғни ішкі байланыстары тығыз, ал сыртқы байланыстары сирек топтарды табады (seed = 42, нәтиже қайталанады):

$$Q = (1 / 2m) \cdot \Sigma_{ij} \left[A_{ij} - k_i \cdot k_j / 2m \right] \cdot \delta(c_i, c_j)$$

A — көршілес матрица, k — түйін дәрежесі, m — қабырғалар саны, δ = 1, егер i мен j бір қауымдастықта болса.

9.3. Желі бонусы

Кластер тәуекелі — кластер жазбаларының ішіндегі «Жоғары» деңгейлілердің үлесі. Жазба мына шарттардың бәрі орындалса ғана **желі бонусын** алады:

- жазбаның өз ұпайы ≥ 14 (кемінде «Орташа»);
- кластерде ≥ 2 аккаунт бар және оларды төлем немесе жарнама нысаны (карта, телефон, промокод, сілтеме, домен) байланыстырады;
- кластер тәуекелі ≥ 0.5.

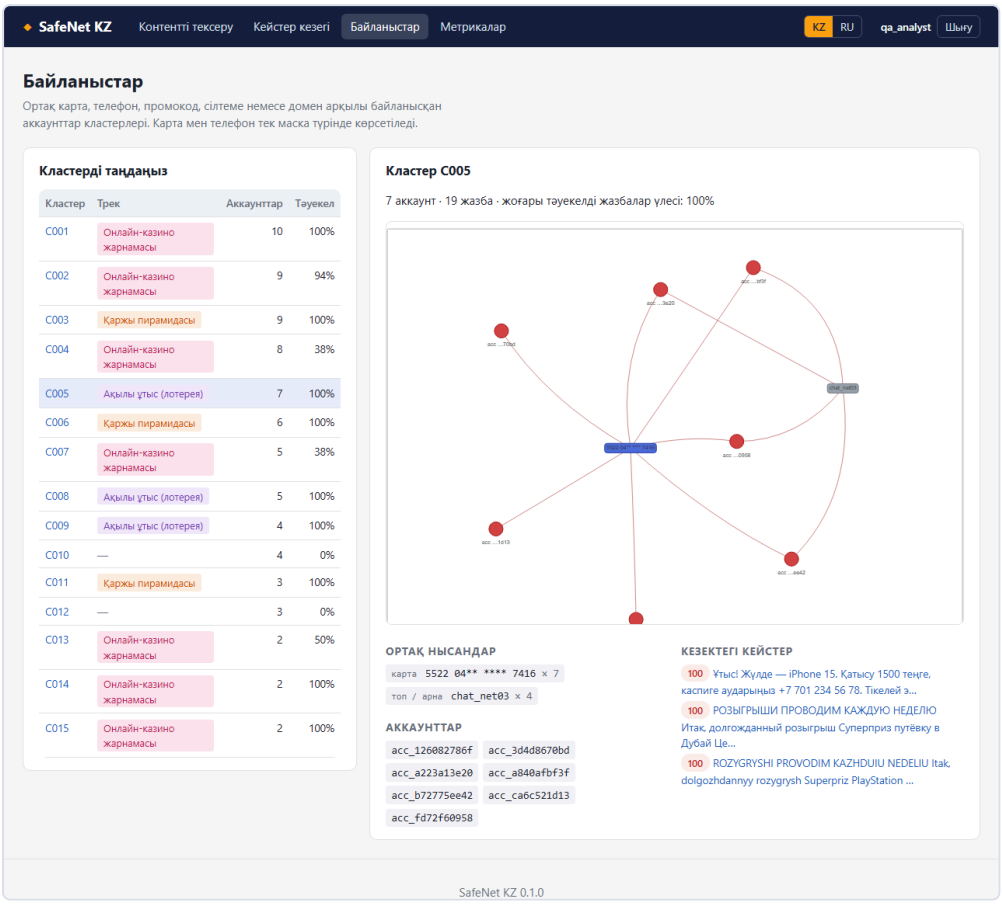
$$\text{желі бонусы} = 10 \times \text{кластер тәуекелі} \quad (\text{ең көбі } +10)$$

Бонус жазбаны «Төменнен» «Орташаға» көтере алмайды, тек «Орташа» мен «Жоғары» арасындағы шекараға әсер етеді. Бұл адал аккаунттарды тек ортақ байланыс үшін күдікке ілікпейтін етеді.

9.4. Нәтижелер

Көрсеткіш	Мәні
Түйіндер / қабырғалар	4265 / 2167
Кластерлер (≥ 2 аккаунт)	15
Ендірілген желілер табылды (қатысушылардың ≥ 70%-ы бір кластерде)	**10 / 10**

Көрсеткіш	Мәні
Тұзақ-дүкендерге берілген бонус	**0**
Графты құру уақыты (талап < 10 с)	1.19 с



4-сурет. «Байланыстар» беті: кластерлер тізімі және интерактивті граф (pyvis).

10 Нәтиже және түсіндірме

Әр талдаудың нәтижесі бір құрылымға (Pydantic схемасы `AnalysisResult`) сәйкес келеді. Ол API-да да, дашбордта да бірдей.

Өріс	Мазмұны
`risk_score`, `risk_level`	Тәуекел ұпайы (0–100) және деңгейі (low / medium / high)
`primary_track`, `tracks`	Ең ықтимал схема түрі және әр тректің ұпайы мен ықтималдығы
`signals`	Іске қосылған белгілер: атауы (KZ/RU), салмағы, ұпайға үлесі, дәлел-фрагменттері (мәтін, позиция, дереккөз), қосымша есептеулер (мысалы, айлық табыс)
`negative_signals`	Ұпайды төмендеткен белгілер
`combos`, `adjustments`	Үйлесім бонустары және шектеуіштер (rule_cap, no_core, clip)
`ml`	Модельдің ең ықтимал класы, ықтималдығы және ұпайға үлесі
`network`	Кластер, оның өлшемі мен тәуекелі, ортақ нысандар (маскаланған), бонус
`explanation_kk`, `explanation_ru`	Адам оқитын қысқа түсіндірме
`disclaimer_kk`, `disclaimer_ru`	Ескерту: шешімді маман қабылдайды
`entities`	Табылған нысандар (карта мен телефон тек маска түрінде)
`ocr_text`, `ocr_confidence`, `warnings`	OCR нәтижесі және ескертулер (мысалы, OCR қолжетімсіз)

Түсіндірме мысалы (2.2-бөлімдегі пост)

> «Анықталған белгілер (4): Шынайы емес табыс уәдесі; Табысқа кепілдік / тәуекелсіз; Асықтыру; Жеке хатқа шақыру. Белгілердің үйлесімі: Шынайы емес табыс + асықтыру немесе көпдеңгейлі модель. Схеманың ең ықтимал түрі: қаржы пирамидасы (модель ықтималдығы 98%). Тәуекел деңгейі: жоғары (98/100).»

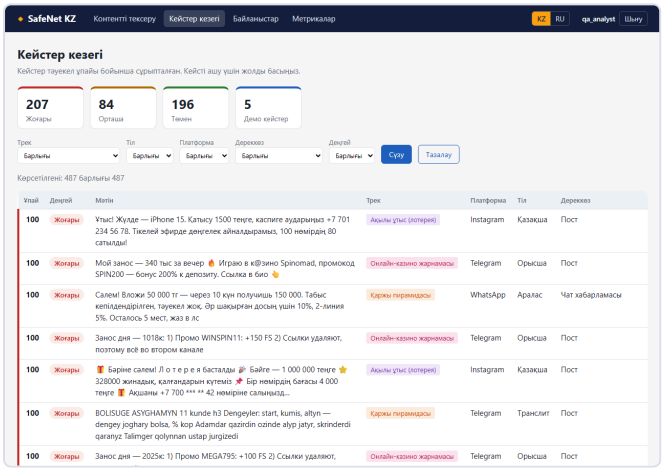
Түсіндірмелер сапасы да өлшенеді: дұрыс табылған схемалардың **100%**-ында жүйе көрсеткен белгілердің кемінде біреуі эталон белгілермен сәйкес келеді (Жаккар ұқсастығы: test 0.922, gold 0.868).

11 Веб-қосымша: дашборд және API

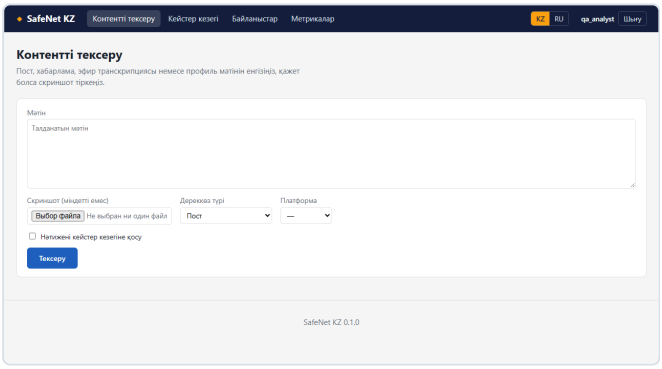
Веб-қабат **Django 6.1** негізінде жасалған. Аналитик дашборды — Django шаблондары, API — **django-ninja** (OpenAPI құжатымен). Интерфейс екі тілде: қазақ және орыс.

11.1. Дашборд беттері

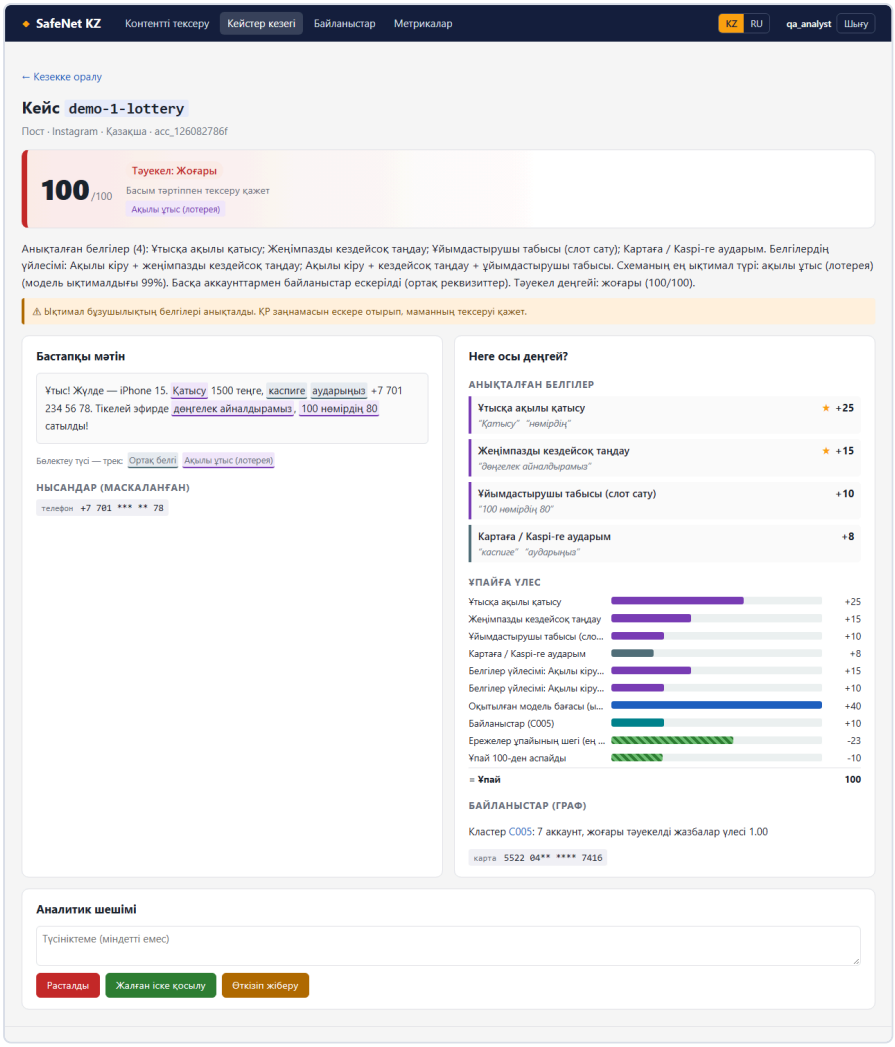
Бет	Не үшін
Кейстер кезегі (`/`)	Аналитиктің жұмыс тізімі. Кейстер ұпай бойынша сұрыпталған; трек, тіл, платформа, дереккөз, деңгей бойынша сүзгілер
Кейс карточкасы (`/case/<id>/`)	Бастапқы мәтін, түспен бөлектелген дәлелдер, «Неге осы деңгей?» панелі, ұпайға үлес диаграммасы, байланыстар, аналитик шешімі
Контентті тексеру (`/check/`)	Бір мәтінді немесе скриншотты қолмен тексеру; нәтижені кезекке қосу
Байланыстар (`/network/`)	Кластерлер, интерактивті граф, ортақ нысандар, кластер аккаунттары
Метрикалар (`/metrics/`)	Сапа көрсеткіштері, толық бағалау есебі, қателерді талдау



5-сурет. Кейстер кезегі



6-сурет. Контентті тексеру



7-сурет. Кейс карточкасы: дәлелдер бөлектелген, ұпай құрамы көрсетілген.

11.2. Аналитик шешімі және кері байланыс

Кейс карточкасында аналитик үш шешімнің бірін қояды: **«Расталды»**, **«Жалған іске қосылу»** немесе **«Өткізіп жіберу»** (жүйе тәуекелді төмен бағалады), түсініктеме де жаза алады. Шешім дерекқорға және `data/feedback/feedback.csv` файлына жазылады: кім, қашан, қандай шешім қойды. Бұл деректер кейін сөздікті, модельді және шектерді қайта баптауға қолданылады.

11.3. Рөлдер

Рөл	Құқықтары
`analyst`	Барлық беттерді көру, контентті тексеру, нәтижені кезекке сақтау, шешім қою
`observer`	Тек көру (шешім мен сақтау батырмалары жасырылады, сервер оларды бәрібір тексереді)
әкімші	`/admin/` : пайдаланушылар, рөлдер, API токендері

11.4. API

Әдіс және жол	Не істейді
`POST /analyze`	Бір мәтінді талдайды (мәтін, дереккөз түрі, платформа, аккаунт). `save: true` нәтижені кезекке қосады
`POST /analyze/image`	Скриншотты (қаласаңыз, мәтінмен бірге) талдайды

Әдіс және жол	Не істейді
`POST /batch`	Бірнеше жазбаны бір сұраумен талдайды
`GET /health`	Сервис күйі (токенсіз тек `status` пен `version`)
`GET /docs`	OpenAPI құжаты (тек жүйеге кірген пайдаланушыға)

- **Кіру:** Bearer-токен. Токенді `manage.py create_api_token <атау>` жасайды, ол бір рет қана көрсетіледі, ал дерекқорда тек SHA-256 хэші сақталады. Токенді `/admin/`-де кері қайтарып алуға болады.
- **Сұраулар лимиті:** бір токенге әдепкі бойынша минутына 600 сұрау (`SAFENET_API_RATE`); асса — 429.

```
curl -X POST https://<сервер>/analyze \
     -H "Authorization: Bearer sn_..." -H "Content-Type: application/json" \
     --data-binary '{"text": "Вложи 10 000 — получишь 30 000!", "source_type": "post"}'
```

12 Сапаны бағалау

12.1. Әдіс

Жүйе екі тәуелсіз жинақта бағаланды:

- **test** — 482 синтетикалық жазба, шаблондары оқытуда да, баптауда да болмаған;
- **gold** — қолмен жазылған 122 хабарлама, ешқандай баптауға қолданылмаған.

Жазба «белгілер бар» деп саналады, егер деңгейі «Орташа» немесе одан жоғары болса (ұпай ≥ 14). Метрикалардың мағынасы:

- **Precision** — жүйе «белгілер бар» деген жазбалардың ішінде шынымен схема болғандарының үлесі (жалған дабыл аз ма?);
- **Recall** — барлық схемалардың ішінде жүйе тапқандарының үлесі (өткізіп алу аз ма?);
- **F1** — precision мен recall-дың гармоникалық ортасы;
- **FPR** — схема емес жазбалардағы жалған дабыл үлесі; **қиын негативтерде** бөлек өлшенеді.

12.2. Негізгі нәтижелер (гибрид)

Жинақ	n	Precision	Recall	F1	FPR	FPR (қиын негатив)
test	482	**0.972**	**0.969**	**0.970**	4.1%	6.4%
gold	122	**0.975**	**0.987**	**0.981**	4.5%	3.4%

Техникалық тапсырманың мақсатты мәндері (test): precision ≥ 0.85 ✅, recall ≥ 0.80 ✅, қиын негативтердегі FPR ≤ 10% ✅.

Тректер бойынша (F1)

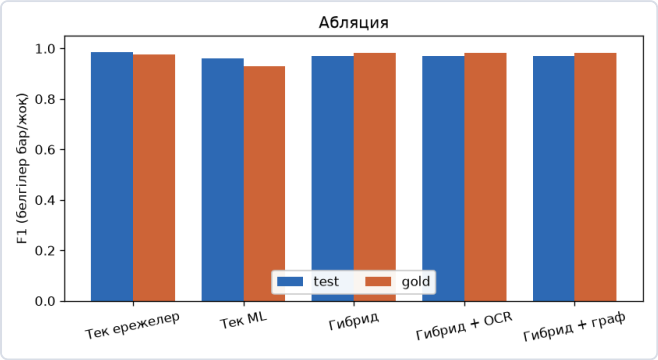
Трек	test precision	test recall	test F1	gold precision	gold recall	gold F1
Ақылы ұтыс	0.890	0.937	0.913	0.963	1.000	0.981
Казино	0.970	1.000	0.985	0.893	0.962	0.926
Пирамида	1.000	0.906	0.951	0.958	0.885	0.920
macro-F1			**0.949**			**0.942**

12.3. Абляция: әр бөліктің үлесі

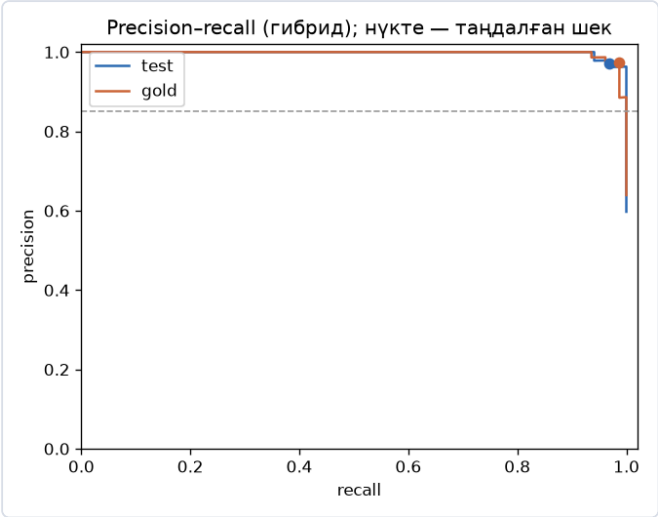
Абляцияда жүйенің бөліктері кезекпен өшіріліп, нәтиже салыстырылады. Әр нұсқаның шегі val жинағында бірдей критериймен таңдалды.

Нұсқа	Шек	test F1	test FPR (қиын)	gold P	gold R	gold F1	gold FPR (қиын)
Тек ережелер	5	0.986	4.5%	0.963	0.987	0.975	6.9%
Тек ML	24	0.960	11.8%	0.914	0.949	0.931	20.7%
Гибрид (ережелер + ML)	14	0.970	6.4%	0.975	0.987	**0.981**	**3.4%**
Гибрид + OCR	14	0.970	6.4%	0.975	0.987	0.981	3.4%
Гибрид + граф	14	0.970	6.4%	0.975	0.987	0.981	3.4%

- **Gold жинағында** (авторға «соқыр», тәуелсіз жинақ) гибрид ең жақсы: F1 0.981, ал қиын негативтердегі жалған дабыл тек ережелерге қарағанда 2 есе аз (3.4% / 6.9%), тек ML-ге қарағанда 6 есе аз (3.4% / 20.7%).
- **Синтетикалық test-те** тек ережелер сәл жоғары (0.986). Себебі сөздік пен генератор фразаларын бір автор жазған, сондықтан test ережелер үшін оптимистік. Бұл ашық көрсетілген шектеу (16-бөлім).
- **OCR мен граф** «белгілер бар/жоқ» метрикаларын өзгертпейді: OCR тек скриншоттарға әсер етеді, ал граф бонусы тек «Орташа» мен «Жоғары» арасындағы шекараға әсер етеді.



8-сурет. Абляция: F1 нұсқалар бойынша



9-сурет. Precision–recall қисығы; нүкте — жұмыс шегі

12.4. Тілдер мен бүркемелеу бойынша (test, гибрид)

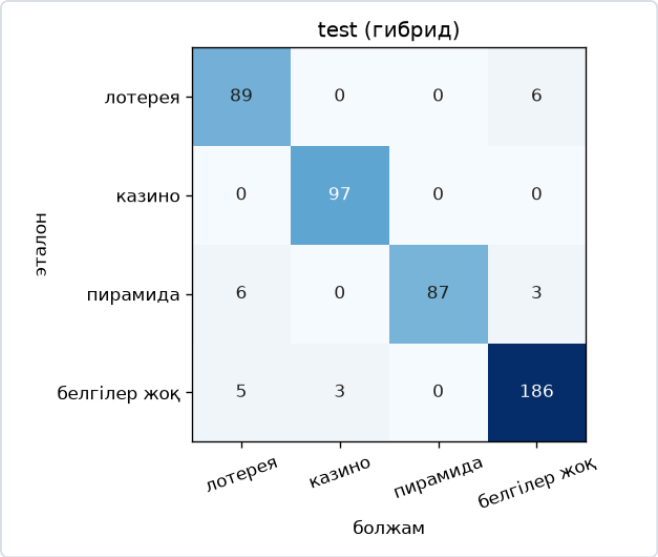
Тіл	n	Precision	Recall	F1
қазақ	140	0.975	0.929	0.952
орыс	210	0.967	0.975	0.971
аралас	66	0.977	1.000	0.989
транслит	66	0.974	1.000	0.987

Бүркемелеу	n	Precision	Recall	F1
бар	138	0.981	1.000	0.990
жоқ	344	0.967	0.952	0.960

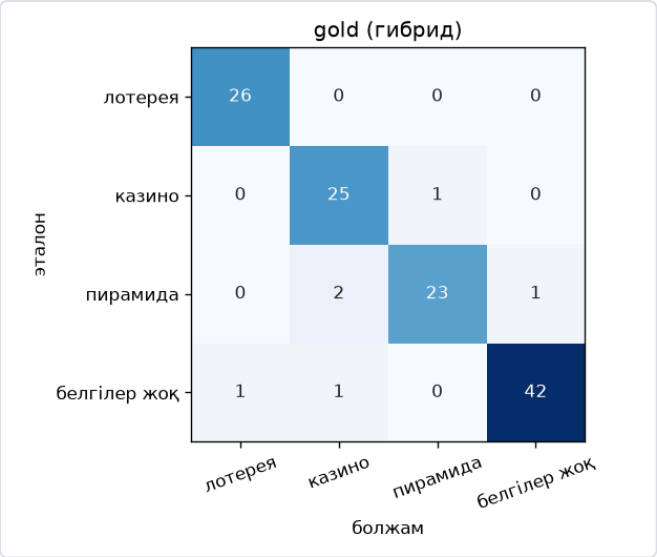
Бүркемеленген мәтіндердегі нәтиже бүркемеленбегендерден кем емес. Бұл нормализацияның тиімді екенін көрсетеді.

12.5. Тәуекел деңгейлері және қателер матрицасы

Болжанған деңгейдің (Төмен / Орташа / Жоғары) эталон деңгейімен сәйкестігі (test): дәлдік **0.923**, macro-F1 **0.902**.



10-сурет. Қателер матрицасы, test



11-сурет. Қателер матрицасы, gold

12.6. Қателерді талдау

test пен gold бойынша барлығы **10 жалған іске қосылу** (FP) және **10 өткізіп алу** (FN) бар. Әр қатенің себебі автоматты түрде анықталады (`reports/errors.md`):

- **Өткізіп алулардың 9-ы — скриншоттар**, негізінен төлем түбіртектері («Kaspi аударым … слот №37 үшін»). Онда «ақылы қатысу» сөзі жоқ, сондықтан тек әлсіз белгілер іске қосылады.
- **Жалған іске қосылулардың 8-і — қиын негативтер**: ескерту мәтіндері, онда төмендететін белгі бар, бірақ ол ұпайды жеткілікті төмендетпеді. Қалған 2-і — қалыпты контент (мысалы, репетитор жарнамасы).
- **Жақсарту бағыты:** өткізіп алынған тұжырымдарды аналитиктің кері байланысы арқылы сөздікке қосу, ескерту мәтіндері үшін төмендететін белгілерді кеңейту.

12.7. Автоматты тесттер

Жобада әр кезеңге арналған тесттер бар (`tests/test_stageNN_*.py`): **728 тест өтеді**, 1 тест белгілі шектеуге байланысты «күтілетін сәтсіздік» (xfail) ретінде белгіленген. Тесттер нормализацияны, белгілерді, модельді, скорингті, OCR-ды, графты, API-ды, дашбордты, құжаттардағы сандардың есептермен сәйкестігін, қауіпсіздік баптауларын және беттерде айыптау сөздері мен ашық нөмірлердің жоқтығын тексереді.

13 Өнімділік және масштабтау

13.1. Өлшенген уақыт

Өлшем	Мәні
Ережелер (нормализация + белгілер), мс/жазба	2.62
ML (батч), мс/жазба	2.89
Толық талдау (OCR-сыз), мс/жазба	5.68
OCR, мс/скриншот	367
Каскад: схемалардың келесі сатыға жіберілгені	100.0%
Каскад: қарапайым контенттің сүзілгені	96.4%
Мысал: шыңдағы ағын, жазба/с	347
Мысал: CPU ядролары — ережелер / ML / OCR	0.9 / 0.3 / 12.8

Машина: Windows 11, 12 логикалық ядро, бір ағынды Python. Бағалау консервативті.

Қорытынды: ережелер мен ML өте арзан, бір ядро секундына жүздеген жазбаны өңдейді. Негізгі шығын — OCR.

13.2. Өнімдік архитектура

Ірі ағын үшін (тәулігіне миллиондаған жазба) мынадай сызба ұсынылады:

1. **Коллекторлар:** платформалардың ресми API-лары, «сенімді хабарлаушы» бағдарламалары, ашық арналар, азаматтардың шағымдары. Карта мен телефон нөмірлері осы жерде хэштеледі.
2. **Kafka** кезегі (`content.raw`); партиция кілті — `account_id` .
3. **Ережелер каскады** — арзан бірінші саты (~2–3 мс). Бірде-бір белгі іске қоспаған жазба (қарапайым контенттің 96%-ы) қымбат сатыларға жіберілмейді.
4. **OCR пулы** — бөлек воркерлер; алдында қайталанатын суреттер perceptual hash арқылы алынады.
5. **ML және скоринг** батчпен, **граф** инкременталды жаңарады (толық Louvain — түнде бір рет).
6. **Қойма:** PostgreSQL (кейстер, шешімдер, аудит), объект қоймасы (скриншоттар).
7. **Дашборд және API** — күйсіз Django процестері, жүктеме теңестіргіштің артында.
8. **Кері байланыс** → қайта оқыту → жаңа нұсқа алдымен «көлеңкелі» режимде салыстырылады.

14 Қауіпсіздік, деректерді қорғау және этика

14.1. Қол жеткізу

- **Барлық беттер жүйеге кіруді талап етеді.** Сессия 8 сағат, браузер жабылғанда аяқталады.
- **Құпиясөз саясаты:** кемінде 10 таңба; жиі қолданылатын және тек сандардан тұратын құпиясөздерге тыйым.
- **Сәтсіз кірулерді шектеу:** бір пайдаланушы аты мен адрестен 5 сәтсіз кіру → 15 минутқа бұғат.
- **Рөлдер** (`analyst` , `observer`); рөлі жоқ пайдаланушы 403 алады.
- **Аудит журналы** (`logs/audit.log`): кіру/шығу, сәтсіз кіру, кейсті ашу, тексеру, шешім қою, API шақырулары — кім, қашан, қай адрестен.
- **Продакшн режимі** (`SAFENET_ENV=production`): HTTPS, қауіпсіз cookie, HSTS, қауіпсіздік тақырыптары; әлсіз құпия кілтпен немесе `DEBUG` қосулы күйде іске қосылмайды (`manage.py check --deploy`).

14.2. Жеке деректерді қорғау

- Карта мен телефон графта тек **SHA-256 хэш**, интерфейсте тек **маска** түрінде көрсетіледі. Тесттер беттерде ашық нөмірлердің жоқтығын тексереді.
- Жүктелген скриншот серверде сақталмайды, тек танылған мәтін қолданылады.
- Аккаунттар идентификатормен белгіленеді.

14.3. Этика

- **Үкім емес, белгілер.** Интерфейс пен API жауаптарында айыптау мағынасындағы сөздер қолданылмайды. Тыйым салынған сөздер тізімі кодта бекітілген, тесттер оларды барлық бетте, API жауаптарында және түсіндірмелерде тексереді.
- **Түсіндірілетін шешім.** Әр деңгейдің артында нақты белгілер мен мәтіннен алынған дәлелдер тұр.
- **Адамның шешімі.** Жүйе ешқандай автоматты шара қолданбайды, тек кезекті басымдық бойынша реттейді.
- **Ашықтық.** Метрикалар, абляция, қателер мен шектеулер ашық көрсетіледі; gold пен test баптауға қолданылмайды.

15 Орнату және іске қосу

15.1. Талаптар

- Python 3.12 немесе жаңарақ;
- Tesseract 5 (міндетті емес: онсыз скриншоттар мәтінсіз талданады);
- продакшнда: PostgreSQL, waitress (Windows) немесе gunicorn + nginx (Linux).

15.2. Әзірлеу ортасында іске қосу

```
python -m venv .venv
.venv\Scripts\activate                # Linux: source .venv/bin/activate
make install data train eval app      # Windows-та: make.bat install data train eval app
python manage.py createsuperuser      # бірінші әкімші
```

Команда	Не істейді
`make install`	Тәуелділіктерді орнатады
`make tessdata`	Tesseract-тың rus/kaz тілдік деректерін жүктейді
`make data`	Синтетикалық датасет (2400 жазба, 130 скриншот) және gold-жинақ
`make train`	ML-модель, белгілер есебі, шектерді таңдау, байланыстар графы
`make eval`	Сапаны бағалау: метрикалар, абляция, графиктер, қателерді талдау
`make app`	Әзірлеу сервері: http://127.0.0.1:8000
`make demo`	Әзірлеу сервері + 5 дайын демо кейс
`make serve`	Продакшн сервері (waitress, `SAFENET_ENV=production`)
`make bench`	Өнімділікті өлшеу
`make test`	Барлық тесттер

15.3. Продакшнда іске қосу

1. `.env` файлында баптаулар: `SAFENET_ENV=production`, құпия кілт, рұқсат етілген хосттар, дерекқор (PostgreSQL), HTTPS.
2. Дерекқорды дайындау: `python manage.py migrate`, әкімшіні жасау: `createsuperuser`.
3. Синтетикалық тест кейстерін тазалау: `python manage.py purge_cases --origin dataset demo --yes`.
4. Аналитиктерді `/admin/`-де қосып, рөл беру; интеграциялар үшін `create_api_token`.
5. Іске қосу: `make serve` (Windows) немесе gunicorn + nginx + systemd (Linux).

Толық нұсқаулық: `docs/DEPLOYMENT.md` (сақтық көшірме, жаңарту, логтар, іске қосар алдындағы тексеріс тізімі).

16 Шектеулер және даму жоспары

16.1. Шектеулер

- **Синтетикалық деректер.** Сөздік пен генераторды бір автор жазған, сондықтан test нәтижесі ережелер үшін оптимистік. Gold тәуелсіз, бірақ шағын (122). Нақты деректердегі сапа пилотта өлшенуі керек.
- **Төлем түбіртектері.** Ақылы қатысу сөзі жоқ түбіртек тек әлсіз белгі береді, сондықтан өткізіп алынуы мүмкін. OCR латын сөздерін бұзуы мүмкін («Kaspi» → «Kaзр!»).
- **«Орташа» шегі төмен (14).** Бір ғана негізгі белгі «Орташа» деңгей береді. Бұл өткізіп алуды азайтады, бірақ аналитикке жүктеме қосады.
- **Аралас тілді анықтау** дәлдігі 72.8%.
- **Бейне мен аудио жоқ.** Эфирлер тек дайын транскрипция арқылы өңделеді.
- **Сөздікке тәуелділік.** Жаңа сленг пен жаңа схема түрлері сөздікті жаңартуды талап етеді. ML мен аналитиктің кері байланысы бұл тәуелділікті азайтады, бірақ толық жоймайды.

16.2. Даму жоспары

Кезең	Мерзім	Нәтиже
0. MVP	дайын	Белгілер, ML, скоринг, OCR, граф, API, дашборд, метрикалар, продакшн баптаулары
1. Пилот	1–3 ай	Нақты деректе 2–3 мың жазба белгіленеді, сапа қайта өлшенеді; мақсат — «Жоғары» кейстердің ≥ 80%-ы расталады
2. Платформалармен интеграция	3–6 ай	Ағынды жинау, Kafka каскады, PostgreSQL, SSO
3. Кері байланыс бойынша қайта оқыту	6 айдан бастап	Ай сайынғы цикл: шешімдер → қайта оқыту → шектерді қайта таңдау; белсенді оқыту
4. Бейне мен аудио	9–12 ай	Сөйлеуді тану (ASR, мысалы Whisper), бейне кадрларынан OCR
5. Ведомствоаралық алмасу	12 айдан бастап	Индикаторлармен (домендер, карта хэштері, промокодтар) қауіпсіз алмасу

A Жоба құрылымы

```
app/                  Django: баптаулар, URL, dashboard/ (беттер, рөлдер)
src/safenet/          негізгі кітапхана
  generator/          синтетикалық деректер және gold-жинақ
  preprocess/         нормализация, тілді анықтау, нысандар
  signals/            белгілер детекторы (config/signals.yaml)
  ml/                 ML-классификатор: фичалар, оқыту, болжау
  scoring/            тәуекел ұпайы, деңгейлер, түсіндірмелер, шектерді таңдау
  multimodal/         OCR және скриншоттар
  graph/              байланыстар графы, кластерлер, визуализация (pyvis)
  eval/               метрикалар, абляция, қателерді талдау, бенчмарк
  api/                django-ninja API
  pipeline.py         analyze() / analyze_many() – бірыңғай кіру нүктесі
config/               signals.yaml, scoring.yaml, demo_cases.yaml
data/                 synthetic/, gold/, images/, demo/, feedback/
models/               clf.joblib, thresholds.json, graph.joblib, tessdata/
reports/              метрикалар мен есептер
docs/                 METHODOLOGY, ARCHITECTURE, ROADMAP, PITCH, DEPLOYMENT
tests/                әр кезеңнің тесттері
```

Пайдаланылған технологиялар

Технология	Нұсқа	Қолданылуы
Python	3.12+	Негізгі тіл
Django	6.1	Веб-қосымша, дашборд, пайдаланушылар мен рөлдер
django-ninja, Pydantic	1.7 / 2.14	REST API, OpenAPI құжаты, нәтиже схемасы
scikit-learn	1.9	TF-IDF, логистикалық регрессия, калибрлеу
NumPy, SciPy, pandas	2.5 / 1.18 / 3.0	Есептеулер, сирек матрицалар, деректер
Tesseract, pytesseract, Pillow	5.4 / 0.3 / 13.0	OCR және суретті өңдеу
NetworkX, pyvis	3.7 / 0.3	Граф, Louvain кластерлеуі, интерактивті визуализация
matplotlib	3.11	Бағалау графиктері
PyYAML, joblib	6.0 / 1.6	Конфигурация, модельді сақтау
SQLite / PostgreSQL	—	Дерекқор (әзірлеу / продакшн)
waitress / gunicorn, whitenoise	3.0 / 23.0 / 6.12	Продакшн сервері, статикалық файлдар
pytest, pytest-django	9.1 / 4.14	Автоматты тесттер

Б Терминдер сөздігі

Термин	Мағынасы
Белгі (signal)	Схемаға тән нақты элемент (мысалы, ақылы қатысу, рандомайзер). Сөздікте сипатталған ереже арқылы табылады.
Негізгі белгі (★)	Схеманың өзегін құрайтын белгі. «Жоғары» деңгей үшін кемінде біреуі міндетті.
Төмендететін белгі	Схема емес екенін көрсететін контекст (тегін қатысу, ескерту, банк ставкасы…). Ұпайды азайтады.
Дәлел (evidence)	Белгіні іске қосқан мәтін фрагменті және оның мәтіндегі орны.
Трек	Схема түрі: ақылы ұтыс, казино, пирамида.
Қиын негатив	Схемаға ұқсайтын, бірақ схема емес мәтін.
train / val / test	Оқыту, баптау (шектер мен гиперпараметрлерді таңдау) және тәуелсіз тексеру жинақтары.
Gold-жинақ	Қолмен жазылған, тек соңғы бағалауға арналған тәуелсіз жинақ.
TF-IDF	Терминнің құжаттағы жиілігін оның корпустағы сирек кездесуімен салмақтайтын мәтінді векторлау әдісі.
n-грамм	Қатар тұрған n таңба (символдық) немесе n сөз (сөздік) тізбегі.
Логистикалық регрессия	Фичалардың сызықтық комбинациясын softmax арқылы класс ықтималдығына айналдыратын модель.
Калибрлеу	Модель ықтималдығын шынайы жиілікке сәйкестендіру (Platt scaling).
Precision / Recall / F1	Дабылдардың дұрыс үлесі / табылған схемалар үлесі / олардың гармоникалық ортасы.
FPR	Схема емес жазбалардағы жалған дабыл үлесі.
Абляция	Жүйе бөліктерін кезекпен өшіріп, әрқайсысының үлесін өлшеу.
OCR	Суреттегі мәтінді оптикалық тану.
Otsu бинаризациясы	Суретті ақ-қараға бөлетін шекті гистограмма бойынша автоматты түрде табу әдісі.
Кластер	Ортақ реквизиттер арқылы байланысқан аккаунттар тобы.
Louvain	Граф модульдігін барынша арттыру арқылы қауымдастықтарды табатын алгоритм.
Хэш (SHA-256)	Нөмірді қайтымсыз кодқа айналдыру: бірдей нөмірлер бірдей хэш береді, бірақ хэштен нөмірді қалпына келтіру мүмкін емес.